

Praktické paralelní programování

Dokumentace k projektu č. 1

MPI a paralelní I/O

Dominik Huml (xhumld00)

May 7, 2026

1 Úvod

Projekt implementuje paralelní simulaci šíření tepla 2D doménou pomocí metody konečných diferencí (FDTD). Paralelizace je realizována kombinací MPI (rozdělení domény mezi procesy) a OpenMP (vlákna uvnitř procesu). Výměna halo zón je implementována dvěma způsoby (P2P a RMA). Průběh simulace je ukládán do souboru HDF5 s podporou paralelního zápisu.

2 Popis implementace

Dekompozice domény

Implementace podporuje 1D dekompozici ($n_x = P$, $n_y = 1$, dělení pouze v jednom směru) a 2D dekompozici (čtvercové nebo obdélníkové dlaždice dle parity $\log_2 P$). Topologie procesů je kartézská (`MPI_Cart_create`). Komunikační skupina je určena pomocí `MPI_Cart_shift`.

Překrytí výpočtu a komunikace

Každá iterace probíhá ve čtyřech fázích, (1) `computeHaloZones` vypočítá okrajové buňky dlaždice (data k odeslání), (2) `startHaloExchange{RMA | P2P}` zahájí neblokující výměnu halo zón, (3) `updateTile` aktualizuje vnitřek dlaždice za běhu přenosu, (4) `awaitHaloExchange{RMA | P2P}` čeká na dokončení výměny. Část komunikace tak může probíhat souběžně s výpočtem vnitřní části dlaždice. Přínos překrytí roste s poměrem vnitřku dlaždice k halo zóně: pro 2D dlaždici strany $L = N/\sqrt{P}$ je tento poměr přibližně $L/8$. Při $L = 1024$ (16 procesů, doména 4096^2) je vnitřek dlaždice $128\times$ větší než halo, takže překrytí má dostatečný výpočetní prostor.

RMA implementace s `MPI_Put`, `packingem` a `PSCW`

Pro RMA halo výměnu byly experimentálně porovnány dva přístupy. Varianta s `MPI_Get` a strided MPI datovými typy (přímé čtení z paměti souseda) se na architektuře Cascade Lake s Intel MPI RDMA cestou ukázala jako extrémně pomalá, naměřeno $55\text{--}80\times$ zpomalení oproti variantě s `MPI_Put`. Zvolená implementace proto používá `MPI_Put`, kdy každý proces *zapisuje* svá halo data do okna souseda. Data jsou před přenosem zabalena pomocí `MPI_Pack/Unpack` do spojitého bufferu, čímž se eliminují strided přístupy. Pro synchronizaci je použit protokol PSCW (`MPI_Win_post/start/complete/wait`), který synchronizuje pouze přímé sousedy dlaždice namísto globální bariéry `MPI_Win_fence`.

Příspěvky jednotlivých optimalizací k celkovému zrychlení RMA (16 procesů, 1-2 uzly, variabilní velikosti dlaždic):

Optimalizace	Zrychlení
MPI_Get $\rightarrow$ MPI_Put	55-80 $\times$
Packing (MPI_Pack/Unpack)	1,5-3 $\times$
Fence $\rightarrow$ PSCW (1 uzel)	1,15 $\times$
Fence $\rightarrow$ PSCW (2 uzly)	1,74 $\times$
<i>Kombinovaný efekt (naive $\rightarrow$ optimalizováno)</i>	
2D, 1 uzel	164 $\times$
1D, 1 uzel	268 $\times$
2D, 2 uzly	133 $\times$

Paralelní I/O a HDF5 chunkování

Parametr `H5Pset_chunk` určuje, jak HDF5 rozdělí dataset do bloků. Nastavení tohoto parametru na rozměr celé globální domény zajistí jeden společný blok pro všechny procesy a umožní skutečně kolektivní zápis. Při nastavení odpovídajícím lokální dlaždici vzniká velké množství malých nezávislých bloků, což při vyšším počtu MPI procesů vede k mnohonásobně delším časům zápisu. Nastavení `H5Pset_chunk` na rozměr celé domény v kombinaci s Lustre stripingem (`lfs setstripe -S 1M -c 16`) přineslo **řádové zrychlení oproti původní paralelní variantě s lokálními chunky**.

3 Škálování

Silné škálování je měřeno na mřížkách 256-4096 při 1-128 procesech (MPI 2D) resp. 1-32 MPI procesů $\times$ 8 vláken (Hybrid 2D) nebo 1-16 MPI procesů $\times$ 16 vláken (Hybrid 1D), celkem až 256 jader na 8 uzlech Barbory. Jako referenční čas slouží sekvenční implementace na téže velikosti domény. Pro doménu 4096^2 je sekvenční čas 53,6 s / 488 iterací $\approx 0,110$ s/iteraci.

Nejlepší naměřené zrychlení:

Konfigurace	Jader	Čas/iteraci [s]	Zrychlení
Hybrid 2D P2P (32 MPI $\times$ 8 OMP)	256	$1,65 \times 10^{-4}$	$\sim 666\times$
Hybrid 1D P2P (16 MPI $\times$ 16 OMP)	256	$2,70 \times 10^{-4}$	$\sim 407\times$
MPI 2D P2P (128 MPI $\times$ 1 OMP)	128	$3,11 \times 10^{-4}$	$\sim 354\times$

Zrychlení Hybrid 2D je **superlineární** vůči ideálnímu 256 $\times$. Příčinou je cache efekt. Sekvenční solver pracuje s doménou 4096^2 (≈ 130 MB), která se nevejde do L3 cache (24,75 MB/socket). U 32 procesů má každá dlaždice rozměr 1024×512 floatů (≈ 2 MB) a dvě teplotní pole mají dohromady přibližně 4 MB, takže se vejdou do L3. Výpočet běží z cache místo RAM.

Rozdíl 1D a 2D dekompozice

Klíčovým faktorem je objem komunikace na proces. Pro P procesů a mřížku $N \times N$ platí:

$$V_{1D} = 4N \quad (\text{dvě plné hrany šířky 2}), \quad V_{2D} = \frac{8N}{\sqrt{P}} \quad (\text{čtyři kratší hrany}), \quad \frac{V_{1D}}{V_{2D}} = \frac{\sqrt{P}}{2}.$$

Při $P = 16$ posílá 1D **2 $\times$** více dat, při $P = 256$ již **8 $\times$** více. V praxi Hybrid 1D dosahuje na 256 jádrech zrychlení $\approx 407\times$ oproti $\approx 666\times$ u Hybrid 2D, tj. $\sim 1,6\times$ horší výsledek. Z 90 přímých srovnání (Hybrid 1D vs. Hybrid 2D při shodném počtu jader, velikosti domény, komunikačním módu a režimu I/O) zvítězila 2D dekompozice v 63 případech ($\sim 70\%$).

Vyrovnanost zátěže

Doména je rozdělena na dlaždice stejné velikosti, takže každý proces aktualizuje shodný počet bodů. Stencil výpočet (`computePoint`) provede pevný počet operací na bod nezávisle na materiálových parametrech. Profilování (viz sekci 4) potvrzuje uniformní rozložení jak výpočetní zátěže, tak objemu zaslaných halo dat.

Vliv paralelního I/O


Naměřené časy pro Hybrid 2D P2P, 16 MPI $\times$ 8 OMP (128 jader):

Režim I/O	Doména 1024 ²	Doména 4096 ²
Bez I/O	0,72 s	1,55 s
Sekvenční	2,07 s	7,58 s
Paralelní	13,7 s	25,9 s


Paralelní HDF5 I/O je při použitých velikostech domén pomalejší než sekvenční zápis. Důvodem je kombinace malých jednotlivých zápisů (4–64 MB na snapshot) a režie Lustre OST koordinace.

Slabé škálování


Velikost úlohy roste úměrně s počtem MPI procesů (65 536 buněk/rank, body 4×512^2 až 256×4096^2). Iterační čas s rostoucím P mírně roste u všech implementací, což odpovídá očekávané sub-ideální efektivitě: MPI 2D drží 82,2 % na 256 jádrech (nejstabilnější), Hybrid 2D 78,5 % na 128 jádrech, Hybrid 1D klesá na 55,5 % na 256 jádrech kvůli většímu komunikačnímu objemu. Hybridní varianty mají nižší absolutní iterační čas díky OpenMP threadům ve sdílené paměti (kratší halo zóny mezi procesy).




(a) Silné škálování: čisté MPI s 2D dekompozicí, výměna okrajů pomocí P2P.



(b) Silné škálování: čisté MPI s 2D dekompozicí, výměna okrajů pomocí RMA.




(c) Cena výpočtu: čisté MPI s 2D dekompozicí, výměna okrajů pomocí P2P.




(d) Cena výpočtu: čisté MPI s 2D dekompozicí, výměna okrajů pomocí RMA.


Figure 1: Silné škálování a cena výpočtu: čisté MPI s 2D dekompozicí.




(a) Silné škálování: hybridní MPI s 2D dekompozicí, výměna okrajů pomocí P2P.



(b) Silné škálování: hybridní MPI s 2D dekompozicí, výměna okrajů pomocí RMA.




(c) Cena výpočtu: hybridní MPI s 2D dekompozicí, výměna okrajů pomocí P2P.




(d) Cena výpočtu: hybridní MPI s 2D dekompozicí, výměna okrajů pomocí RMA.


Figure 2: Silné škálování a cena výpočtu: hybridní MPI s 2D dekompozicí.




(a) Silné škálování: hybridní MPI s 1D dekompozicí, výměna okrajů pomocí P2P.



(b) Silné škálování: hybridní MPI s 1D dekompozicí, výměna okrajů pomocí RMA.



(c) Cena výpočtu: hybridní MPI s 1D dekompozicí, výměna okrajů pomocí P2P.



(d) Cena výpočtu: hybridní MPI s 1D dekompozicí, výměna okrajů pomocí RMA.

Figure 3: Silné škálování a cena výpočtu: hybridní MPI s 1D dekompozicí.




Figure 4: Slabé škálování (65 536 buněk/rank): iterační čas (vlevo) mírně roste se zvyšováním P , efektivita (vpravo) klesá pod 100 % kvůli komunikační režii. 2D dekompozice si drží lepší efektivitu než 1D.

4 Profilování

4.1 Vampir

Trasování bylo provedeno pro konfiguraci P2P 2D, doména 1024^2 , 16 procesů, 100 iterací. Časová osa všech procesů (obr. 5) ukazuje pravidelně se opakující strukturu iterací, ve které se střídají fáze lokálního výpočtu (hnědé) s fázemi MPI volání (modře). Hnědé bloky výpočtu zabírají dominantní část plochy, modré bloky mají ale nezanedbatelnou délku, především na konci každé iterace. Jde převážně o čekání v `awaitHaloExchange` na synchronizaci se sousedy před další iterací. Komunikační matice (obr. 6) zachycuje rozdíl mezi 1D a 2D dekompozicí. V 1D vzniká úzký diagonální pás, neboť každý rank komunikuje jen se dvěma sousedy v řadě, a maximum barevné škály dosahuje 840 KiB. 2D má širší vzor díky čtyřem sousedům dlaždice, ale maximum škály klesá na 210 KiB kvůli kratším hranám ($N/\sqrt{P}$ vs. N). Souhrn doby strávené v jednotlivých funkcích na rank (obr. 7) potvrzuje, že `computePoint` dominuje napříč všemi 16 ranky s velmi malými rozdíly mezi nimi.






Figure 5: Vampir Master Timeline (P2P, 2D, 1024^2 , 16 procesů, zoom na jednu iteraci).




(a) 1D dekompozice (16×1).




(b) 2D dekompozice (4×4).

Figure 6: Vampir Communication Matrix (Aggregated Message Volume), 16 procesů.



(a)



(b)

Figure 8: Cube, kartézská topologie procesů s metrikou bytes_sent, 16 procesů.

5 Závěr

Implementace dosahuje superlineárního zrychlení $\sim 666\times$ (Hybrid 2D P2P, 256 jader, doména 4096^2 , bez I/O). RMA výkon byl zlepšen celkově $133\text{--}268\times$ oproti výchozímu stavu, přičemž dominantním příspěvkem je nahrazení MPI_Get za MPI_Put ($55\text{--}80\times$), sekundárně packing ($1,5\text{--}3\times$) a PSCW synchronizace ($1,15\text{--}1,74\times$ dle počtu uzlů). 2D dekompozice překonává 1D v 63 z 90 přímých srovnání díky $\sqrt{P}/2$ -krát menšímu objemu komunikace na proces. Oprava HDF5 chunkování a Lustre striping výrazně zrychlily paralelní zápis oproti původní variantě s lokálními chunky. Pro měření objemy dat ale paralelní I/O stále zůstalo pomalejší než sekvenční zápis.